

Detection of protein–small-molecule binding sites

Final Defence

Веб-инструмент: PDB → 2 метода детектирования карманов → 3D-визуализация → DCC-метрика → бенчмарк.

Команда: Абабкова В.А., Базуев Р.Д., Пупейко Д.Н., Янгалин И.А.

Saint Petersburg 2026 · Project №4 (K. Pavel) · 16.05.2026

Зачем

- **Drug discovery:** прежде чем подбирать молекулу, надо знать **куда** она сядет.
- Со-кристаллография и NMR — дорогие и медленные.
- Геометрические и ML-методы предсказывают сайт за **секунды** по 3D-структуре.
- **Сложность:** разные методы видят разные сайты (ортостерический vs аллостерический vs cryptic). Никакой ground-truth «лучше» — нужна сравнительная оценка.
- **Наш вклад:** end-to-end-инструмент, запускающий 2 метода рядом, и численная оценка (DCC) против co-crystallized лиганда.

Goal & Objectives — итог

Goal: Веб-сервис PDB → пайплайн P2Rank + fpocket → 3D-visualisation + comparison + DCC.

#	Objective	Outcome
O1	Обернуть P2Rank (ML, surface-based)	✓ wrapper + parser, 4 кармана для 1FBL
O2	Обернуть fpocket (геометрический)	✓ wrapper + parser, 19 карманов для 1FBL
O3	Единая Pydantic-схема для обоих методов	✓ <code>MethodResult</code> <code>Pocket</code> <code>Metrics</code>
O4	3D-визуализация + cross-method comparison	✓ 3Dmol.js + distance/Jaccard матчинг
O5	Бенчмарк 15 PDB + DCC top-N	✓ P2Rank 69% ≥ acceptance 65%
O6	Apo/holo case study	✓ HSP90: cryptic site detected by P2Rank

Tool spec — финальный контракт

Входы: PDB-файл или PDB ID (RCSB fetch).

Выходы (`GET /api/jobs/{id}`):

```
{  "status": "done",  "pdb_id": "1FBL",  "results":    {    "p2rank":    {    "pockets": [{"rank": 1, "score": 9.77, "center": [70.5, 83.4, -11.5], "residues": [...]}, ...],    "fpocket": {...}    },    "comparison": [{"p2rank_rank": 1, "fpocket_rank": 1, "distance": 4.25, "jaccard": 0.74}, ...],    "metrics":    {    "p2rank":    {    "dcc_top1": 5.96, "success_top3": false,    "fpocket":    {    "dcc_top1": 3.55, "success_top3": true    }    }    }
```

Дополнительно: `GET /results.csv` · `GET /structure` (очищенный PDB для отрисовки).

Архитектура



Live demo — 1FBL

Protein binding-site detection

P2Rank vs fpocket — comparison & 3D visualization

INPUT

PDB ID:

1FBL

or

Upload PDB:

Choose File

No file chosen


Predict

status: done

SHOW METHODS

☒ P2Rank

☒ fpocket



METHOD COMPARISON

P2Rank #1 ↔ fpocket #1: 4.25 Å apart · Jaccard 0.74				
p2rank	DCC top-1: 5.96 Å	X	fpocket	DCC top-1: 3.55 Å ✓
P2RANK	↔	FPOCKET	Δ, Å	JACCARD
#1	↔	#1	4.25	0.74
#2	↔	#9	3.85	0.67
#3	↔	#10	10.76	0.00
#4	↔	#2	0.74	0.60

POCKETS

Download CSV

METHOD	RANK	SCORE	CENTER (Å)	RESIDUES
p2rank	1	9.77	70.5, 83.4, -11.5	A_103, A_180, A_181, A_182, A_183, A_184, A_186, A_214...
p2rank	2	3.04	89.2, 98.6, 26.8	A_337, A_339, A_341, A_348, A_357, A_360, A_362, A_366...
p2rank	3	2.94	61.1, 70.7, -13.6	A_119, A_156, A_160, A_162, A_164, A_168, A_191, A_194...

Cross-method comparison panel

METHOD COMPARISON

P2Rank #1 ↔ fpocket #1: 4.25 Å apart · Jaccard 0.74

p2rank DCC top-1: 5.96 Å ✗ · fpocket DCC top-1: 3.55 Å ✓

P2RANK	↔	FPOCKET	Δ, Å	JACCARD
#1	↔	#1	4.25	0.74
#2	↔	#9	3.85	0.67
#3	↔	#10	10.76	0.00
#4	↔	#2	0.74	0.60

Benchmark · COACH420 subset (15 PDB)

Метод	Top-3 success @ 4 Å	Avg per-PDB time
P2Rank	9 / 13 = 69% ≥ acceptance 65% (P2Rank-paper ≈70%)	~7 с
fpocket	8 / 13 = 62%	~7 с

- 2 PDB graceful-skip — нет co-crystallized лиганда (1OWT, 1G3K).
- Полный прогон: **~2 минуты** на ноутбуке.
- Метрика **DCC** (Distance to Center of Cocrystal): евклидово расстояние от центра кармана до центроида co-crystallized лиганда; top-3 success = $\min(\text{DCC}[1..3]) \leq 4 \text{ Å}$.

Apo/holo case study · HSP90 (1YES ↔ 1YET)

Структура	Метод	Top-1 center	DCC к holo-сайту	Verdict
apo (1YES)	p2rank	(38.9, -45.4, 63.0)	3.66 Å	✓ cryptic site found
apo (1YES)	fpocket	(34.3, -63.9, 62.6)	18.88 Å	✗ wrong pocket
holo (1YET)	p2rank	(38.2, -46.2, 62.8)	4.11 Å	—
holo (1YET)	fpocket	(40.0, -45.4, 62.2)	3.76 Å	—

- **P2Rank top-1 apo и holo разнесены на 1.16 Å** — метод нашёл cryptic site **на apo-форме**, где лиганда нет.
 - **fpocket разнос 19.35 Å** — геометрия видит крупный карман в неправильном месте.
- Это ключевой кейс «зачем ML, а не только геометрия» для drug discovery.

Failure cases — где методы ломаются

Из 13 успешно прогнанных PDB P2Rank проваливается на 4:

PDB	DCC top-1	Причина
1IEP	60 Å	Метод реально промахнулся (STI = Imatinib единственный лиганд)
2RH1	22 Å	Auto-detect выбрал CLR (холестерин, аллостерический) вместо CAU (каразолол)
4COX	23 Å top-1 / 1.7 Å top-3 ✓	Auto-detect выбрал HEM (гем) вместо IMN (индометацин)
3PXF	6.4 Å	Метод нашёл соседний карман, чуть мимо

Половина «провалов» — артефакт auto-detect heuristic, фиксируется `ligand_resname` override в CSV. Это известная проблема: «крупнейший HETATM ≠ интересующий лиганд» для белков с кофакторами.

Тесты и качество

- **56 unit-тестов** (pytest) — все green.
- **18/18 smoke** — end-to-end against running API.
- Покрытие критичных модулей: P2Rank-parser, fpocket-parser, preprocess, comparison, DCC, fetch-cache, REST API, валидация PDB-ID.
- **Offline cache** (Risk R4 mitigation): `data/pdb_cache/` с 6 демо-PDB; `fetch_pdb` сначала смотрит локально, потом RCSB.
- Воспроизводимость: один `conda env annc` (Python 3.13, Java 17, fpocket 4.0); `scripts/run.sh` поднимает всё.

Risk mitigation — что сработало

Риск	Mitigation	Outcome
R1: Java/P2Rank сборка глючит	conda env с openjdk-17, явный install-скрипт	не воспроизвёлся
R3: 3Dmol тормозит на больших структурах	warning при > 8000 атомов в <code>loadStructure</code>	актуально для 4COX
R4: нет интернета на защите	<code>data/pdb_cache/</code> + cache-first fetch	демо 100% offline
R5: биология аро/holo требует биолога	Взяли каноничную пару HSP90 1YES/1YET из литературы	кейс отработал
R6: DCC-числа не совпадут с paper	Acceptance 65% ≥ P2Rank-paper ≈70%, threshold 4 Å	69% получили
R7: Поломка за день до защиты	15.05 code-freeze, только репетиция	соблюдено

Выводы

1. **End-to-end-инструмент собран и работает** — PDB-вход → 2 метода → 3D-vis → DCC-метрика → CSV-выгрузка.
2. **Сравнение методов даёт реальную ценность**: P2Rank лучше на cryptic sites, fpocket точнее на «классических» карманах с явной геометрией.
3. **Числа подтверждены экспериментально**: 69% top-3 success на 15-PDB подмножестве — в пределах опубликованных значений P2Rank-paper (~70%).
4. **Apo/holo case** наглядно показал, ради чего ML-метод полезен в drug discovery: cryptic site (3.66 Å DCC) поймать удалось.
5. **Failure cases классифицированы** — половина артефактов auto-detect heuristic, остальное — реальные провалы методов.

Repo & demo

- **Локальный путь:** `~/Рабочий стол/ANNC/binding-sites`
- **Запуск:** `./scripts/run.sh` → <http://localhost:8000>
- **Демо-PDB pre-cached** в `data/pdb_cache/` : 1FBL, 1ATP, 1HSG, 1AKE, 1YES, 1YET
- **Бенчмарк:** `python -m benchmark.run` (~2 мин)
- **Аро/holo:** `python -m benchmark.apo_holo --apo 1YES --holo 1YET`

Команда: Абабкова В.А. · Базуев Р.Д. · Пупейко Д.Н. · Янгалин И.А.

Q&A

Готовы к вопросам.

Final Defence · 16.05.2026 · Project №4 · Saint Petersburg 2026